MODELOS DE RAZONAMIENTO | COMPARATIVA RÁPIDA

Actualizado: 23 oct 2026 · Costes de API estándar publicados; no equivalen al gasto de créditos de ChatGPT/Codex.

Modelo	Perfil oficial resumido	Razonamiento API	Entrada $/1M	Salida $/1M	Coste ejemplo*	Coste relativo	Uso recomendado
GPT-5.6 Luna	Eficiente · alto volumen	none / low / medium / high / xhigh / max	$0,20	$1,00	$0,04	Muy bajo	Extracción, clasificación y tareas acotadas
GPT-5.6 Terra	Equilibrio capacidad-coste	none / low / medium / high / xhigh / max	$2,00	$12,00	$0,44	Bajo	Trabajo cotidiano, documentos y programación
GPT-5.6 Sol	Más capaz de la familia 5.6	none / low / medium / high / xhigh / max	$4,00	$20,00	$0,80	Medio	Tareas complejas y ambiguas
GPT-6 Luna	Más eficiente de la familia 6	none / low / medium / high / xhigh / max	$0,10	$0,50	$0,02	Muy bajo	Tareas enfocadas y repetibles
GPT-6 Sol	Modelo fuerte de propósito general	none / low / medium / high / xhigh / max	$4,00	$20,00	$0,80	Medio	Programación y flujos de trabajo complejos
GPT-6 Astra	Máxima capacidad de la familia 6	low / medium / high / xhigh / max	$10,00	$50,00	$2,00	Alto	Análisis exigente y proyectos amplios
GPT-6.1 Sol	Cercano a Astra a menor coste	low / medium / high / xhigh / max	$2,00	$10,00	$0,40	Bajo	Trabajo complejo con control del gasto

MÉTRICA DE RENDIMIENTO-CONSUMO

Métrica recomendada: tasa de éxito por coste = tareas correctas ÷ coste total (o porcentaje de éxito ÷ coste). Para que sea justa, ejecuta el mismo conjunto de tareas, con el mismo contexto, herramientas y criterio de aprobado. Esta medida no se calcula aquí porque OpenAI no publica una puntuación comparable de éxito para todas estas combinaciones.

**Escenario ilustrativo: 100.000 tokens de entrada + 20.000 de salida, sin caché, API estándar. Coste de tokens visibles; el razonamiento interno puede aumentarlo. «Coste relativo» compara solo el ejemplo, no el gasto de suscripción.*

AJUSTES DE RAZONAMIENTO — consumo esperado, no multiplicador fijo

Ajuste UI	Equivalencia orientativa	Razonamiento/token esperado	Tiempo espera	Cuándo usarlo
Ligero	Low	Bajo	Rápido	Consultas directas y cambios pequeños
Medio	Medium	Moderado	Normal	Uso general
Alto	High	Alto	Más lento	Diagnóstico y tareas de varios pasos
Muy alto	Extra High / xhigh	Muy alto	Más lento	Problemas difíciles con varias condiciones
Ultra	Subagentes (modo Codex)	Variable; puede sumar agentes	Variable	Tareas grandes que pueden dividirse

Importante: los niveles no son equivalentes exactos entre generaciones. Ultra no es un nivel de esfuerzo individual; activa trabajo con subagentes. “Muy alto” es la aproximación visual a Extra High. Disponibilidad según cuenta, plan y cliente.

Fuentes: developers.openai.com/api/docs/pricing · /models/gpt-5.6-terra · /models/gpt-6.1-sol · learn.chatgpt.com/docs/models · learn.chatgpt.com/docs/pricing